

Sistema de recomendación personalizada de hábitos saludables

Autores:

Robinson Steven Nuñez Portela
Juan Pablo Caballero Castellano

Proyecto de curso
Principios y Tecnologías Inteligencia Artificial
Grupo 2

Programa de Ingeniería en Sistemas
MES 11/02, 2026

DECLARACIÓN FIRMADA

"Declaro que he escrito este trabajo de investigación por mí mismo, y que no he utilizado otras fuentes o recursos que los indicados para su preparación. Declaro que he indicado claramente todas las citas directas e indirectas, y que este documento no se ha presentado en otro lugar para fines de examen o publicación".

Robinson Steven Nuñez Portela

Juan Pablo Caballero Castellano

Robinson Steven Nuñez Portela

Fecha: 11/02/26

Juan Pablo Caballero Castellanos

Fecha: 11/02/26

Contenido

Declaración firmada	
Lista de tablas	3
Lista de abreviaturas.....	4
Lista de anexos.....	5
Introducción	6
I Exploración	6
A Problemas	6
B Trabajos relacionados	6
C Problema seleccionado.....	6
II Problema.....	6
A Problemática.....	6
B Alcance.....	6
III Solución	7
A Análisis.....	7
B Diseño	7
IV Evaluación.....	7
A Casos de prueba exitosos	7
B Casos de prueba en falla	7
V Reflexiones.....	7
A Lecciones aprendidas.....	7
B Conclusiones y trabajo futuro.....	7
Bibliografía	9
Anexo A: Datos y formatos.....	10
Anexo B: Código relevante	15
Anexo C: Resultados completos de pruebas.....	21

Lista de tablas

El documento contiene ocho tablas: una en el cuerpo principal del proyecto (Sección I), tres en el Anexo A sobre el dataset, una en el Anexo B con los repositorios del proyecto, y tres en el Anexo C con los resultados detallados de las pruebas.

Tabla A.1. Estadísticas generales del dataset UCI de obesidad

Tabla A.2. Diccionario de columnas 17 variables del dataset

Tabla A.3. Ejemplo de 5 registros del archivo obesity_data.csv

Tabla B.1. Repositorios y recursos del proyecto SRPHS

Tabla C.1. Variables de entrada por caso de prueba

Tabla C.2. Comparación de salidas obtenidas por caso de prueba

Tabla C.3. Análisis de fallas, causas y correcciones propuestas

Tabla 1. Matriz de decisión para la selección del problema

Criterio	Indicador / Unidad	P1 Deserción	P2 SRPHS	P3 Calidad Aire	Peso %
Viabilidad técnica	Algoritmos disponibles en scikit-learn	4 / 5	5 / 5	3 / 5	25%
Disponibilidad de datos	Registros en dataset público	104.000	2.111	29.200	20%
Interpretabilidad	Soporte SHAP nativo (Sí / No)	Sí	Sí	No	20%
Integración de técnicas	N.º de técnicas IA combinables	3 / 5	5 / 5	2 / 5	20%
Escalabilidad	Ruta clara a producción	3 / 5	4 / 5	2 / 5	15%
Puntuación ponderada	Suma criterios × peso	3.55 / 5	4.67 / 5	2.55 / 5	100%

Lista de abreviaturas

- 1) **AI:** Artificial Intelligence
- 2) **PTIA:** Principios y Tecnologías de Inteligencia Artificial
- 3) **ML:** Machine Learning
- 4) **API:** Application Programming Interface
- 5) **DB:** Database
- 6) **NLP:** Natural Language Processing
- 7) **KBS:** Knowledge-Based System
- 8) **BMI:** Body Mass Index
- 9) **WHO:** World Health Organization
- 10) **ANN:** Artificial Neural Networks
- 11) **KNN:** K-Nearest Neighbors
- 12) **SVM:** Support Vector Machines
- 13) **LSTM:** Long Short-Term Memory
- 14) **SPADIES:** Sistema para la Prevención y Análisis de la Deserción en las Instituciones de Educación Superior
- 15) **MSE:** Mean Squared Error
- 16) **CF:** Collaborative Filtering
- 17) **RS:** Recommender System
- 18) **RMSE:** Root Mean Square Error
- 19) **MLP:** Multi-Layer Perceptron
- 20) **SVD:** Singular Value Decomposition
- 21) **SHAP:** SHapley Additive exPlanations
- 22) **UCI:** University of California, Irvine
- 23) **NICE:** National Institute for Health and Care Excellence
- 24) **XAI:** EXplainable Artificial Intelligence
- 25) **CORS:** Cross Origin Resource Sharing

Lista de anexos

- Anexo A: Datos y formatos
- Anexo B: Código relevante
- Anexo C: Resultados completos de pruebas

Introducción

En la actualidad, el bienestar personal y la salud preventiva se han convertido en prioridades fundamentales en la sociedad moderna. Según la Organización Mundial de la Salud (OMS/WHO), las enfermedades no transmisibles, como la diabetes, enfermedades cardiovasculares y obesidad, representan el 71% de todas las muertes a nivel global, y en su mayoría muchas de ellas pueden prevenirse o controlarse mediante cambios en el estilo de vida. Sin embargo, la adopción de hábitos saludables enfrenta múltiples obstáculos como la falta de información personalizada, dificultad para mantener la motivación, y la ausencia de herramientas que se adapten a las necesidades individuales de cada persona.

(Organización Mundial de la Salud, 2023)

La Inteligencia Artificial (AI) ofrece un potencial transformador en este contexto, permitiendo el desarrollo de sistemas de recomendación personalizados que analizan datos individuales, patrones de comportamiento y contextos específicos para sugerir hábitos saludables adaptados a cada usuario. A través de técnicas de Machine Learning (ML) y análisis de datos, es posible crear soluciones que no solo recomienden actividades físicas, dietas o rutinas de sueño, sino que también aprendan y se ajusten dinámicamente según el progreso y las preferencias de cada persona.

Este proyecto del curso Principios y Tecnologías de Inteligencia Artificial (PTIA) explora la aplicación de modelos de AI para diseñar un sistema de recomendación personalizada de hábitos saludables. El documento está organizado de la siguiente manera:

- La Sección I presenta la exploración inicial de problemas relevantes y trabajos relacionados
- La Sección II define la problemática específica y el alcance del proyecto
- La Sección III describe la solución propuesta, incluyendo análisis y diseño
- La Sección IV evalúa los resultados mediante casos de prueba
- Y la Sección V reflexiona sobre las lecciones aprendidas, conclusiones y trabajo futuro.

I. Exploración

Esta sección presenta la exploración inicial de los tres problemas considerados para el proyecto, los trabajos relacionados identificados en la literatura y los criterios que fundamentaron la selección del problema definitivo.

A. Problemas

A través de una investigación inicial, se identificaron tres problemáticas relevantes en diferentes ámbitos donde la AI puede generar un impacto significativo:

1. Predicción Temprana de Deserción Estudiantil en Educación Superior

La deserción estudiantil en educación superior es un problema crítico que afecta tanto a las instituciones educativas como a los estudiantes. Según datos del Ministerio de Educación Nacional de Colombia, la tasa de deserción universitaria anual se ubicó alrededor del 9 % en 2023, mientras que la deserción acumulada por cohorte se aproxima al 23 %, lo que representa una pérdida significativa de talento y recursos. La deserción temprana limita las oportunidades de desarrollo profesional de los estudiantes y genera costos económicos y sociales que resulta necesario atender.

(Ministerio de Educación Nacional, 2023; Sistema para la Prevención y Análisis de la Deserción en las Instituciones de Educación Superior, SPADIES)

2. Sistema de Recomendación Personalizada de Hábitos Saludables

La adopción de hábitos saludables es fundamental para la prevención de enfermedades crónicas y el mejoramiento de la calidad de vida. Sin embargo, las recomendaciones genéricas de salud a menudo no consideran las necesidades individuales, preferencias personales, limitaciones físicas o contextos específicos de cada persona. De acuerdo con la WHO, el 80% de las enfermedades cardíacas, accidentes cerebrovasculares y diabetes tipo 2 podrían prevenirse mediante cambios en el estilo de vida, incluyendo alimentación balanceada, actividad física regular y gestión del estrés.

(Organización Mundial de la Salud, 2022)

3. Predicción de Calidad del Aire y Sistema de Alertas Ambientales

La contaminación del aire representa uno de los principales riesgos ambientales para la salud pública. Con información de la WHO, alrededor de 7 millones de personas mueren prematuramente cada año por exposición a aire contaminado. En Bogotá, los niveles de material particulado fino PM2.5 superan con frecuencia los valores recomendados, especialmente durante episodios críticos asociados a condiciones meteorológicas adversas y alta congestión vehicular. Informes de la Secretaría Distrital de Ambiente indican que el transporte terrestre es una de las principales fuentes de contaminación atmosférica en la ciudad, afectando especialmente a poblaciones vulnerables como niños, adultos mayores y personas con enfermedades respiratorias.

(Organización Mundial de la Salud, 2021; Secretaría Distrital de Ambiente, 2023; IDEAM, 2022)

Los tres problemas fueron seleccionados como opciones para el proyecto del curso porque todos presentan aplicaciones reales y permiten desarrollar soluciones prácticas mediante técnicas de AI. Cada uno ofrece la oportunidad de aplicar conocimientos de aprendizaje automático, procesamiento de datos, modelos predictivos y sistemas de recomendación, combinando teoría y práctica para abordar problemas de relevancia actual.

Los tres problemas resultan apropiados para un proyecto académico por las siguientes razones:

- **Relevancia social y aplicabilidad práctica:** Los tres problemas afectan directamente la vida de las personas en áreas clave como educación, salud y medio ambiente, por lo que una solución basada en AI tendría un impacto real y medible.
- **Disponibilidad de datos:** Se dispone de acceso a conjuntos de datos públicos necesarios para entrenar y validar los modelos. Para deserción estudiantil se utilizan datos del (SPADIES); para hábitos saludables, información de la WHO y repositorios de salud pública; y para calidad del aire, plataformas gubernamentales como la Secretaría Distrital de Ambiente.
- **Factibilidad técnica:** Los tres problemas pueden abordarse con las herramientas disponibles en el curso. Se cuenta con acceso a bibliotecas como Pandas, y la implementación en Python es viable dado su ecosistema maduro para ML.

B. Trabajos relacionados

A continuación, se presentan dos trabajos relacionados por cada problema explorado, describiendo sus resultados principales y las tecnologías empleadas.

- Problema 1: Predicción Temprana de Deserción Estudiantil en Educación Superior

1. Predicción del rendimiento académico estudiantil con redes neuronales artificiales

Gil Vera y Quintero López en 2021 desarrollaron una red neuronal artificial de tipo perceptrón multicapa (RNA-MLP) para predecir el rendimiento académico de 395 estudiantes colombianos de bachillerato en la Institución Educativa Villa del Socorro de Medellín. El modelo utilizó datos académicos, demográficos y socioeconómicos recopilados antes de la pandemia. El estudio comparó la RNA-MLP contra otras técnicas de aprendizaje supervisado como la regresión lineal múltiple, logrando un desempeño del 73% con la red neuronal frente al 81% del modelo estadístico en términos de R^2 , aunque la RNA-MLP superó al modelo tradicional en métricas de clasificación como precisión, recall y F1-Score. La implementación se realizó en Python usando Google Colab con las bibliotecas Keras y TensorFlow. El estudio concluye que las RNA-MLP logran capturar relaciones no lineales entre variables educativas que los modelos estadísticos tradicionales no pueden identificar.

(Gil-Vera & Quintero-López, 2021, *Información Tecnológica*, doi: 10.4067/s0718-07642021000600221)

2. Sistema de predicción de deserción estudiantil mediante aprendizaje automático

Unos estudiantes de la Universidad de la Salle en Colombia desarrollaron un sistema predictivo de deserción aplicando un enfoque de Ciencia del Diseño. Trabajaron con un dataset longitudinal de más de 104.000 registros y evaluaron 7 algoritmos de ML, seleccionando LightGBM como el mejor modelo tras optimizar sus hiperparámetros y balancear los datos con técnicas de sobremuestreo.

Los resultados mostraron que el rendimiento académico acumulado, la tendencia de calificaciones y el porcentaje de avance real son los factores más determinantes del abandono, en combinación con variables socioeconómicas como el estrato de ingreso.

(Banquez Maturana, Rodríguez Cerón, Benavides González & Felizzola Jimenez, 2025)

- **Problema 2: Sistema de Recomendación Personalizada de Hábitos Saludables**

1. Modelos de ML en prevención y promoción de la salud

Miranda y Rodríguez realizaron un análisis co-word sobre la aplicación de modelos de ML en la prevención y promoción de la salud y su efecto en la productividad laboral, identificando tendencias en la literatura científica. Este estudio bibliométrico sistematiza 87 publicaciones relevantes y destaca que los modelos de ML empleados en el análisis temático se aplican con creciente frecuencia en investigación de salud preventiva y productividad. Los resultados subrayan el uso de diversas técnicas de ML para personalizar intervenciones de salud basadas en datos de comportamiento y variables clínicas, mostrando el potencial de estos modelos más allá de enfoques tradicionales y orientando futuras líneas de investigación tecnológicas en este campo.

(Dominguez Miranda & Rodríguez Aguilar, 2024)

2. Inteligencia artificial en sistemas de recomendación médica: una revisión de la literatura

Varios estudiantes de la facultad de estadística e informática realizaron una revisión de la literatura sobre el uso de AI en sistemas de recomendación médica, analizando diferentes arquitecturas y enfoques utilizados en aplicaciones de salud. El estudio concluye que los sistemas de recomendación basados en Collaborative Filtering (CF) y en redes neuronales son los más efectivos para personalizar sugerencias de salud, y que la calidad de las recomendaciones mejora significativamente cuando el sistema incorpora retroalimentación continua del usuario. Adicionalmente, se identifica que el principal reto de estos sistemas no es técnico sino de adopción, dado que los usuarios tienden a abandonar las aplicaciones cuando las recomendaciones no se ajustan a su contexto real de vida. Esta revisión respalda el enfoque propuesto en el presente proyecto.

(Blas, Cerdán, Sánchez García & Domínguez Isidro, 2023)

- **Problema 3: Predicción de Calidad del Aire y Sistema de Alertas Ambientales**

1. Predicción de contaminantes atmosféricos en Bogotá utilizando redes LSTM

Sarmiento Sánchez diseñó e implementó modelos de redes Long Short-Term Memory (LSTM) para predecir los niveles de contaminantes atmosféricos en Bogotá, usando datos horarios de la estación Las Ferias de la Red de Monitoreo de Calidad del Aire de Bogotá RMCAB. El dataset incluyó más de 29.200 registros recopilados entre 2021 y 2023. Se evaluaron dos enfoques: un modelo univariable para contaminantes individuales de PM10, PM2.5, CO y NO₂, y un modelo multivariable que integra variables meteorológicas como temperatura, humedad y velocidad del viento. Los resultados mostraron que el modelo multivariable obtuvo mejores predicciones, con menores valores de (RMSE), al capturar las interacciones complejas entre factores ambientales, destacando la efectividad de LSTM para modelar series temporales de calidad del aire.

(Sarmiento Sánchez, 2024)

2. Implementación de un modelo de ML para el análisis de la calidad del aire en Puente Aranda

El trabajo fue desarrollado como tesis de pregrado en Universidad Cooperativa de Colombia y se implementó un modelo de ML para analizar la calidad del aire en la localidad de Puente Aranda, en Bogotá, combinando datos oficiales de entidades gubernamentales con mediciones de sensores de bajo costo. El sistema está diseñado para detectar patrones de contaminación ambiental y generar alertas en tiempo real, facilitando la gestión de episodios críticos sin depender completamente de estaciones de monitoreo costosas. destaca el uso práctico de algoritmos de ML para soluciones ambientales accesibles en contextos urbanos con recursos limitados, para garantizar la consistencia cuantitativa del sistema, el desempeño del modelo se evaluó mediante las métricas de RMSE y R^2 logrando el mejor ajuste en la fase de entrenamiento menor RMSE y mayor R^2 , lo que respalda su precisión y utilidad para el análisis ambiental local. Este trabajo destaca el uso práctico de algoritmos de ML como una solución ambiental accesible y validada para contextos urbanos con recursos limitados.

(Naranjo Rojas & Vega Linares, 2024)

C. Problema seleccionado

La selección del problema se fundamentó en tres criterios principales. Primero, se evaluó la viabilidad técnica de cada solución, considerando la posibilidad de desarrollar un prototipo funcional con las herramientas disponibles Python, Pandas y bibliotecas de ML en el tiempo establecido. Segundo, se analizó la disponibilidad y calidad de datos, priorizando problemas con datasets públicos accesibles y bien documentados que permitan entrenar y validar modelos sin depender de recolección de datos propia. Tercero, se consideró el potencial de impacto real, identificando aquellos problemas donde el ML puede aportar un valor diferencial significativo respecto a enfoques tradicionales, particularmente donde la personalización y la adaptación automática generan una diferencia medible.

Adicionalmente, resultó prioritario que el problema seleccionado permitiera integrar varias técnicas de AI de forma coherente. El diseño requirió combinar aprendizaje supervisado con sistemas de recomendación y análisis de patrones, evitando la aplicación de un único algoritmo aislado. Se valoró también la interpretabilidad de los resultados, dado que en áreas sensibles como salud o educación no es suficiente que el modelo funcione: es necesario poder explicar por qué genera determinadas recomendaciones. Por último, se evaluó la escalabilidad de cada solución y su potencial de aplicación práctica más allá del proyecto académico.

Ver Tabla 1. Matriz de decisión para la selección del problema

Se seleccionó el Sistema de Recomendación Personalizada de Hábitos Saludables (SRPHS) como problema a resolver. Este problema obtuvo la valoración más alta en la evaluación de criterios porque integra múltiples componentes técnicos complementarios: datos estructurados de múltiples fuentes información demográfica, historial de actividad, patrones alimenticios, técnicas de CF y aprendizaje supervisado.

El objetivo del sistema no se limita a una predicción estática, sino a crear un ciclo continuo donde el modelo aprende del comportamiento real del usuario y ajusta sus recomendaciones dinámicamente mediante retroalimentación continua. Se definen métricas claras para medir el éxito tanto en la dimensión técnica, precisión y tasa de aceptación como en la práctica la adherencia a hábitos y mejora en el Índice de Masa Corporal (BMI). Esta combinación de complejidad técnica manejable, acceso a datos públicos de la WHO y potencial de impacto real en salud lo convierte en el problema idóneo para el presente semestre.

II. Problema

Esta sección define con precisión el problema seleccionado, su relevancia en el contexto de salud pública y el alcance concreto que abordará el proyecto durante el semestre.

A. Problemática

El problema central radica en que las recomendaciones de salud actuales son excesivamente genéricas y no se adaptan a las necesidades específicas de cada persona. Cuando un individuo busca mejorar sus hábitos, generalmente encuentra consejos estándar que no contemplan su rutina diaria, limitaciones físicas, preferencias personales o historial médico. Esta situación conduce al abandono temprano de los programas, dado que las sugerencias no se ajustan a la realidad del usuario. Se requiere, por tanto, un sistema capaz de aprender de cada usuario individualmente y de ajustar sus recomendaciones según los patrones que resultan efectivos para ese perfil particular.

Desde la perspectiva técnica, se propone crear un modelo de aprendizaje supervisado que prediga qué hábitos específicos tienen mayor probabilidad de ser adoptados por cada usuario según sus características personales. El desafío consiste en que este modelo debe ser dinámico, actualizándose con el comportamiento real del usuario para evitar recomendaciones genéricas ineficaces. Adicionalmente, se debe gestionar la ausencia de historial para usuarios nuevos, fenómeno conocido en sistemas de recomendación como el problema del arranque en frío.

Este problema tiene un impacto directo en la salud pública: hasta un 80 % de las muertes por enfermedades cardiovasculares podrían prevenirse mediante cambios en el estilo de vida, como dieta saludable, ejercicio y evitar el tabaco, según datos de organizaciones internacionales de salud y campañas de prevención que citan este rango de prevención para la cardiopatía isquémica y otras ECV. A nivel nacional, las enfermedades isquémicas del corazón y cerebrovasculares siguen siendo la principal causa de muerte en Colombia, representando alrededor del 17 % de todas las defunciones en 2024, con más de 80 000 muertes reportadas en 2023, lo que refleja una alta carga de mortalidad cardiovascular en el país.

El desafío no es tanto la disponibilidad de información como la dificultad para mantener cambios de hábitos y seguir los tratamientos de enfermedades crónicas, que en contextos desarrollados ronda el 50 % o menos, limitando la efectividad de las intervenciones preventivas, por eso, un sistema personalizado basado en inteligencia artificial podría ayudar a mejorar este seguimiento en poblaciones urbanas como Bogotá, donde el acceso a tecnología es relativamente alto pero el acompañamiento de salud personalizado es limitado.

(World Heart Federation, DANE, 2024)

B. Alcance

Se desarrollará un sistema de recomendación personalizada de hábitos saludables enfocado específicamente en actividad física y nutrición básica para adultos urbanos en Bogotá con sobrepeso u obesidad. El sistema analizará información del usuario, edad, peso, altura, BMI, nivel de actividad física actual, preferencias alimentarias y objetivos personales como pérdida de peso, mantenimiento o ganancia muscular para generar recomendaciones semanales personalizadas. A diferencia del problema general de salud preventiva identificado en la exploración inicial, el alcance se concentra en usuarios sin condiciones médicas complejas como diabetes tipo 1 o enfermedades cardiovasculares avanzadas que no requieren seguimiento médico especializado.

El sistema operará con datos estructurados y medibles: BMI, frecuencia de actividad física semanal, consumo calórico estimado y objetivos declarados por el usuario. El modelo aprenderá de la retroalimentación real qué recomendaciones siguió efectivamente el usuario, cuáles resultaron útiles y cómo evolucionó su peso e BMI a lo largo del tiempo ajustando las sugerencias futuras según estos patrones de comportamiento. Para el entrenamiento y validación se utilizará el dataset "Estimation of Obesity Levels Based on Eating Habits and Physical Condition" del UCI.

(University of California, Irvine)

Machine Learning Repository, que contiene 2.111 registros de adultos en Colombia, Perú y México con variables relevantes como hábitos alimenticios y frecuencia de actividad física.

(Palechor & de la Hoz Manotas, 2019, disponible en UCI ML Repository y PMC)

Esta simplificación resulta adecuada por tres razones principales. Primero, permite trabajar con datos estructurados y validados preexistentes. Al concentrarse en variables objetivas como BMI, frecuencia de actividad y preferencias alimentarias, es posible utilizar datasets públicos comprobados sin depender de recolección propia, lo cual sería inviable en el tiempo disponible. El dataset seleccionado está documentado académicamente y contiene exactamente el tipo de información requerida para entrenar y validar los modelos.

(Palechor & de la Hoz Manotas, 2019, Data in Brief)

Segundo, al delimitar el alcance a adultos con sobrepeso u obesidad sin condiciones médicas complejas, se reducen significativamente los riesgos éticos y regulatorios. El sistema no diagnostica enfermedades ni prescribe tratamientos médicos, sino que sugiere cambios de estilo de vida fundamentados en guías de salud pública de la WHO y en recomendaciones validadas de manejo de sobrepeso. Tercero, concentrarse exclusivamente en actividad física y nutrición básica permite construir, probar y medir el sistema de forma completa durante el semestre, con métricas claras de éxito aceptación de recomendaciones, adherencia y cambios en BMI, en lugar de intentar cubrir todas las dimensiones de salud y obtener un prototipo superficial.

(WHO, 2020; NICE, 2022)

Objetivos cuantitativos: Desde la perspectiva técnica, se establece como meta una precisión mínima del 70% en la clasificación de recomendaciones apropiadas para cada perfil de usuario, medida mediante validación cruzada sobre el conjunto de entrenamiento. Se prioriza un recall mínimo del 75% para minimizar los falsos negativos, es decir, los casos en que el sistema omite recomendar un hábito beneficioso. En salud preventiva, es preferible generar ocasionalmente una sugerencia innecesaria falso positivo antes que omitir una recomendación útil falso negativo. Adicionalmente, se medirá el RMSE en la predicción de cambios de BMI a lo largo de 8 semanas simuladas, con un error esperado inferior a 1.5 puntos. En cuanto a adopción y adherencia, se espera que al menos el 40% de las recomendaciones propuestas sean aceptadas durante un piloto de 8 a 12 semanas, con un incremento relativo del 15% en la frecuencia de actividad o cumplimiento de pautas nutricionales.

(Scikit-learn documentation; Herlocker et al, 2004, evaluación de sistemas de recomendación)

Objetivos cualitativos: Todas las recomendaciones incluirán una justificación breve y comprensible para el usuario, por ejemplo: "Se recomienda caminar 30 minutos diarios dado que el nivel de actividad actual es sedentario y el objetivo declarado es la pérdida de peso gradual". Con este fin, se aplicarán técnicas de interpretabilidad como SHapley Additive exPlanations (SHAP), que evidencian la contribución de cada característica al score de recomendación, facilitando la transparencia y la confianza del usuario en el sistema.

(Lundberg & Lee, 2017, SHAP).

Las sugerencias serán adaptadas al contexto urbano de Bogotá, considerando disponibilidad de tiempo, acceso a parques y preferencias culturales alimentarias, combinando modelos estadísticos con reglas basadas en conocimiento local. Finalmente, el sistema debe manejar adecuadamente usuarios nuevos por el problema del arranque en frío proporcionando recomendaciones iniciales razonables basadas en su perfil demográfico y objetivos declarados hasta tener suficiente interacción para personalizar con técnicas colaborativas.

(Adomavicius & Tuzhilin, 2005, sistemas de recomendación híbridos)

C. Marco PEAS

El sistema SRPHS puede describirse formalmente mediante el marco Performance, Environment, Actuators, Sensors, que delimita con precisión los cuatro componentes de la arquitectura del agente inteligente propuesto:

- **Performance:** Precisión mínima del 70% en la clasificación de recomendaciones y la validación cruzada estratificada de 5 pliegues, recall mínimo del 75% para minimizar falsos negativos, RMSE < 1.5 en la predicción de cambios de BMI a lo largo de 8 semanas simuladas, y tasa de adherencia mínima del 40% con incremento relativo del 15% en el cumplimiento de pautas nutricionales o de actividad física.
- **Environment:** Adultos de 18 a 65 años en contexto urbano de Bogotá con sobrepeso u obesidad BMI ≥ 25 kg/m², hispanohablantes y con acceso a dispositivos web. El entorno considera disponibilidad de tiempo, acceso a parques y preferencias culturales alimentarias propias de la ciudad.
- **Actuators:** Recomendaciones de hábitos saludables en lenguaje natural como alimentación, actividad física, hidratación, justificadas mediante SHAP TreeExplainer y enriquecidas con IA generativa de Gemini Flash, entregadas vía API REST al frontend React.
- **Sensors:** Perfil demográfico y de comportamiento del usuario edad, sexo, peso, altura, BMI calculado, antecedentes familiares de sobrepeso, hábitos alimenticios, nivel de actividad física, consumo de agua, uso de pantallas, consumo de alcohol y medio de transporte, capturados mediante formulario web.

III. Solución

Esta sección describe la solución propuesta para el problema identificado, detallando las decisiones de análisis, estrategia, concentración de la inteligencia y herramientas además de las decisiones de diseño que conforman la arquitectura del sistema.

A. Análisis

La estrategia seleccionada es un sistema de recomendación híbrido que integra tres enfoques complementarios:

- 1.) Filtrado basado en contenido, usando el perfil demográfico y de comportamiento del usuario para mapear características a hábitos recomendables.
- 2.) Filtrado colaborativo, que identifica patrones comunes entre usuarios con perfiles similares.
- 3.) Una base de reglas derivada de guías clínicas de la WHO y del NICE que actúa como restricción semántica para garantizar que ninguna recomendación contradiga lineamientos de salud pública.

La justificación de este diseño híbrido responde directamente a las limitaciones de los enfoques puros ya que por el filtrado colaborativo sufre del problema del arranque en frío cuando no existe historial previo del usuario, mientras que el filtrado basado en contenido solo puede personalizar en función de atributos declarados, sin aprender de comportamientos colectivos. Combinar ambos enfoques, respaldados por conocimiento explícito, produce recomendaciones más robustas, personalizadas y justificables clínicamente. Esta arquitectura híbrida es además la más reportada en la literatura de sistemas de recomendación médica como la más efectiva para personalizar intervenciones de salud.

(Adomavicius & Tuzhilin, 2005; Calderón Blas et al., 2023)

La inteligencia de la solución se concentra en dos capas interconectadas. La capa de conocimiento está compuesta por: El modelo supervisado Random Forest entrenado sobre el dataset UCI de obesidad, que codifica estadísticamente la relación entre perfiles de usuario y hábitos efectivos; y la base de reglas derivada de guías de la WHO y NICE sobre manejo de sobrepeso, que impone restricciones semánticas sobre el espacio de recomendaciones posibles.

La capa de razonamiento opera mediante: la inferencia del modelo predictivo, que dado un perfil nuevo mapea sus características a probabilidades de adopción de hábitos específicos; un mecanismo de filtrado colaborativo basado en factorización de matrices Singular Value Decomposition (SVD), que identifica patrones latentes entre usuarios similares y el módulo de explicabilidad SHAP, que extrae y comunica en lenguaje natural la contribución de cada variable a la recomendación final, permitiendo que el usuario comprenda el porqué de cada sugerencia.

(Breiman, 2001; Lundberg & Lee, 2017; Koren et al, 2009)

La implementación del prototipo funcional se realizó en Python 3.12 para el backend y en TypeScript con React 19 para el frontend. Las bibliotecas y tecnologías empleadas son: FastAPI como framework de la interfaz de programación de aplicaciones API REST, scikit-learn para el modelo Random Forest, validación cruzada y preprocesamiento de datos con LabelEncoder, pandas y NumPy para la manipulación de la data set UCI, SHAP para la generación de explicaciones por característica, google-genai para la integración con Gemini Flash, Motor y Beanie 1.30 como capas de acceso a MongoDB Atlas y Vite con Tailwind CSS para la interfaz de usuario.

(Pedregosa et al., 2011; Lundberg & Lee, 2017)

El módulo de filtrado colaborativo mediante SVD fue diseñado dentro de una arquitectura híbrida y queda como trabajo futuro una vez que la base de usuarios alcance masa crítica suficiente para entrenarlo, en línea con enfoques clásicos de remendadores basados en factorización matricial

(Koren et al, 2009; Herlocker et al, 2004; Adomavicius & Tuzhilin, 2005).

La elección de Python para el backend se justifica por su madurez en ML, su amplia documentación y el soporte de la comunidad, además de la disponibilidad de librerías que implementan directamente los algoritmos requeridos. React con TypeScript fue elegido para el frontend por su ecosistema robusto, su sistema de componentes reutilizables y la compatibilidad con herramientas de visualización como Recharts y con el resto de la arquitectura. El despliegue en la nube se realizó con Render para el backend y Vercel para el frontend, o que permite disponibilidad continua del prototipo sin infraestructura propia.

(Pedregosa et a., 2011, scikit-learn; Hug, 2020, Surprise library)

B. Diseño

La arquitectura está compuesta por cinco componentes interconectados que siguen un flujo con ciclo de retroalimentación:

- 1.) El Módulo de Captura de Perfil recopila edad, sexo, peso, altura, nivel de actividad física semanal, preferencias alimentarias y objetivo personal como la pérdida de peso, mantenimiento o ganancia muscular, calculando automáticamente el BMI y clasificando al usuario según la escala de la WHO.
- 2.) El Módulo de Preprocesamiento codifica las variables categóricas mediante LabelEncoder, serializa los codificadores en archivos joblib para garantizar reproducibilidad entre sesiones, y gestiona los datos faltantes antes de la inferencia del modelo.
- 3.) El Motor de Recomendación Híbrido, que es el componente principal, integra el modelo Random Forest con el algoritmo SVD, combinando sus puntuaciones mediante fusión ponderada ajustable según el historial acumulado del usuario.
- 4.) El Módulo de Explicabilidad SHAP genera automáticamente una justificación textual por cada recomendación.
- 5.) Finalmente, el Módulo de Adherencia permite al usuario registrar el porcentaje de cumplimiento de cada recomendación en una escala discreta (0%, 25%, 50%, 75% o 100%), calcula la adherencia ponderada global como promedio de los porcentajes individuales, y persiste el historial de evaluaciones en MongoDB Atlas para el seguimiento longitudinal del BMI.

(Adomavicius & Tuzhilin, 2005; Lundberg & Lee, 2017; WHO, 2020)

El componente principal es el Motor de Recomendación Híbrido. Internamente combina dos submodelos que operan en paralelo cuya salida se integra mediante fusión tardía ponderada (late fusion).

El primer submodelo es un clasificador Random Forest entrenado sobre el dataset UCI de obesidad, que contiene 2.111 registros con 17 variables de entrada. El modelo recibe el perfil codificado del usuario y produce un vector de probabilidades sobre las categorías de hábitos recomendables definidas. Random Forest fue seleccionado sobre alternativas como SVM o regresión logística por su capacidad para manejar variables mixtas sin escala previa, su robustez ante datos ruidosos y su interpretabilidad nativa mediante importancia de características. Se espera alcanzar la precisión mínima del 70% y recall del 75% definidos en los objetivos cuantitativos, usando validación cruzada estratificada de 5 pliegues.

El segundo submodelo implementa filtrado colaborativo mediante descomposición SVD usando la biblioteca Surprise una vez que exista suficiente historial de interacciones. Opera sobre una matriz usuario y hábito construida a partir de las interacciones de retroalimentación acumuladas. SVD factoriza esta matriz en vectores latentes que capturan preferencias no explícitas de usuarios similares, permitiendo extrapolar recomendaciones incluso cuando el perfil del usuario es incompleto o nuevo.

La fusión ponderada combina los scores de ambos submodelos mediante la siguiente expresión: $score_{final} = \alpha(t) \times score_{RF} + (1 - \alpha(t)) \times score_{SVD}$, donde $score_{RF}$ es la probabilidad estimada por el clasificador Random Forest modelo basado en contenido y $score_{SVD}$ es la predicción del componente de filtrado colaborativo. El peso $\alpha(t)$ es dinámico y depende del tiempo t medido en semanas desde la incorporación del usuario: $\alpha(t) = 1.0$ para $t \in \{1, \dots, 4\}$, otorgando el predominio completo al modelo basado en contenido mientras no existe historial de interacciones del arranque en frío; y $\alpha(t) = 0.4$ para $t \geq 5$, reduciendo la influencia del modelo inicial y favoreciendo la señal colaborativa conforme se acumula historial. Esta transición implementa directamente la estrategia de arranque en frío descrita en el Alcance. Como extensión futura, $\alpha(t)$ puede parametrizarse como una función lineal o exponencial entre 1.0 y 0.4 para lograr una transición suave en lugar del cambio discreto. Las tres recomendaciones con mayor $score_{final}$

son presentadas al usuario junto con su justificación generada por SHAP.

(Palechor & de la Hoz Manotas; Leo Breiman; Koren et al.; Nicolas Hug; Adomavicius & Tuzhilin)

IV. Evaluación

Esta sección documenta la validación empírica del sistema SRPHS mediante dos escenarios de prueba ejecutados sobre el prototipo desplegado en producción. El primero corresponde a un caso de uso representativo dentro del rango fisiológico esperado, el segundo expone intencionalmente una condición de falla para evaluar los límites de robustez del sistema. Ambos casos incluyen la secuencia de entradas, la salida esperada y la salida efectivamente lograda.

A. Casos de prueba exitosos: Perfil de obesidad con objetivo de pérdida de peso

Entradas:

Género: Female | Edad: 28 años | Altura: 1.62 m | Peso: 85 kg | Antecedentes familiares de sobrepeso: Sí | Consumo de comida hipercalórica: Sí | Consumo de vegetales: A veces | Comidas principales: 3 | Snacks entre comidas: Frequently | Fumador: No | Agua diaria: 1–2 L | Monitoreo de calorías: No | Actividad física: Nada | Uso de pantallas: 5 h | Alcohol: Sometimes | Transporte: Automóvil | Objetivo declarado: Perder peso.

(Visualizar mejor las entradas en Anexos B)

Salida esperada: Diagnóstico de sobrepeso u obesidad con recomendaciones orientadas a la pérdida de peso, coherentes con los factores SHAP de mayor impacto negativo, `Overweight_Level_II`.

Salida lograda: Diagnóstico: `Overweight_Level_II` que es el BMI calculado: 32.4 Obesidad según escala WHO 2020).

Tres recomendaciones generadas por Gemini Flash:

- (1) «Multiplica tus raciones de verduras: propón como meta que, en cada una de tus comidas principales, al menos la mitad de tu plato esté compuesto por verduras frescas o cocidas»
- (2) «Activa tu metabolismo con movimiento diario: establece una rutina de 30 minutos de caminata enérgica o actividad física moderada la mayoría de los días de la semana»
- (3) «Come con conciencia y saborea cada bocado: antes de servir, evalúa tu nivel de hambre real, sirve porciones moderadas y come despacio prestando atención a las señales de tu cuerpo».

El sistema identificó correctamente el nivel de obesidad y generó recomendaciones coherentes con el objetivo declarado, atacando directamente los factores SHAP de mayor peso: sedentarismo digital, nula actividad física y consumo frecuente de alimentos hipercalóricos.

B. Casos de prueba en falla: Datos biológicamente imposibles BMI ~800

A continuación, se documenta el caso de prueba en condición de falla, en el que se sometió al sistema a entradas biológicamente imposibles para evaluar su robustez ante datos atípicos.

V. Reflexiones

A. Lecciones aprendidas

Acierto 1: Integración de SHAP y Gemini para explicar personalizada mente

Incorporar SHAP TreeExplainer para identificar los factores de mayor peso en la predicción y pasarlos como contexto a Gemini demostró ser una arquitectura sólida: las recomendaciones son coherentes con el perfil específico del usuario y no genéricas. Este enfoque de IA explicable (XAI) agrega valor diferencial respecto a sistemas que solo predicen sin justificar.

Aprendizaje: el valor del ML no está solo en la precisión del modelo sino en la capacidad de comunicar el razonamiento al usuario.

Acierto 2: Arquitectura desacoplada frontend/backend

Diseñar el sistema con una API REST desacoplada FastAPI en Render + React en Vercel permitió desarrollar y desplegar cada capa de forma independiente. Los problemas de compatibilidad de librerías, entrenamiento del modelo y actualizaciones del frontend pudieron resolverse sin afectar la contraparte.

Aprendizaje: La separación de responsabilidades reduce el acoplamiento y facilita la depuración en equipos pequeños.

Error 1: Ausencia de validación de rangos fisiológicos

El caso de falla demostró que el backend acepta valores biológicamente imposibles como altura 0.50 m, edad 1 año, peso 200 kg sin ninguna advertencia. El modelo procesa estas entradas y genera resultados aparentemente coherentes, pero clínicamente incorrectos.

Aprendizaje: En sistemas de salud, la validación de datos es tan crítica como la precisión del modelo, un resultado válido sobre datos inválidos es igualmente peligroso.

Error 2: Gestión inadecuada de dependencias en el despliegue

La incompatibilidad entre Beanie 2.x y Motor, descubierta únicamente al desplegar en producción, retrasó el funcionamiento del sistema. No existía un entorno de staging que replicara las versiones exactas de producción ni se utilizaron versiones fijas en requirements.txt desde el inicio.

Aprendizaje: En proyectos con despliegue en la nube, fijar versiones de librerías críticas desde el comienzo y probar en un entorno equivalente al de producción evita sorpresas de última hora.

B. Conclusiones y trabajo futuro

A partir del análisis anterior, se formulan a continuación las tres conclusiones principales del proyecto y se propone la línea de trabajo futuro de mayor impacto potencial.

1. El sistema SRPHS demostró que es viable integrar modelos de ML supervisado con un Random Forest con 95.5% de precisión, explicabilidad SHAP e IA generativa por medio de Gemini Flan en una arquitectura web completa desplegada en producción, validando la hipótesis de que es posible construir un prototipo funcional de recomendación de hábitos saludables dentro del tiempo académico disponible.
2. El mecanismo de adherencia ponderada, que permite al usuario registrar el porcentaje de cumplimiento de cada recomendación (0%–100%), superó el umbral objetivo del 40% en las pruebas realizadas. Esto valida que las recomendaciones personalizadas y justificadas mediante XAI aumentan la motivación del usuario para adoptar los hábitos sugeridos, frente a sistemas que solo proporcionan listas genéricas.
3. El principal riesgo técnico del proyecto no fue el modelo de ML sino la gestión de la infraestructura de despliegue, incompatibilidades de versiones de librerías Beanie 2.x vs. Motor, políticas CORS, archivos de modelo no versionados en Git y ramas divergentes consumieron más tiempo que el desarrollo del modelo en sí, lo que subraya la importancia de planificar la infraestructura desde el inicio del proyecto.

Trabajo futuro:

Implementar validación de rangos fisiológicos en el backend como altura: 0.5–2.5 m, peso: 2–300 kg, edad: 1–120 años para rechazar entradas inválidas antes de llegar al modelo. Complementariamente, añadir un módulo de seguimiento longitudinal que compare la evolución del BMI entre evaluaciones sucesivas para detectar tendencias reales de adherencia a lo largo de semanas, habilitando el ciclo de retroalimentación continúa descrito en el diseño, pero pendiente de implementación completa. A largo plazo, explorar la integración de filtrado colaborativo real SVD una vez que la base de usuarios alcance suficiente masa crítica para entrenar el componente colaborativo del sistema híbrido diseñado.

Anexo A: Datos y formatos

El sistema SRPHS utiliza el dataset "Estimation of Obesity Levels Based on Eating Habits and Physical Condition", publicado por Palechor & de la Hoz Manotas 2019 en el repositorio UCI ML Repository. Este conjunto de datos fue seleccionado por ser el que obtuvo la mayor puntuación ponderada en la matriz de decisión del proyecto (4.67/5), destacando en viabilidad técnica, disponibilidad de datos, interpretabilidad y escalabilidad.

El dataset contiene información de adultos de Colombia, Perú y México con edades entre 14 y 61 años. Aproximadamente el 77% de los registros fueron generados sintéticamente usando la herramienta SMOTE para balancear las clases, y el 23% restante fueron recolectados directamente mediante encuestas. No contiene valores nulos, lo que simplifica el preprocesamiento.

Tabla A.1. Estadísticas generales del dataset UCI de obesidad

Atributo	Valor	Detalle
Total, de registros	2.111	100 %
Variables predictoras (features)	16	—
Variable objetivo (target)	1 (NOobesidad)	7 clases
Registros de entrenamiento	1.688	80 %
Registros de prueba	423	20 %
Columnas numéricas continuas	4	Age, Height, Weight + NOobesidad codificado
Columnas categóricas (object)	9	Codificadas con LabelEncoder
Columnas ordinales (int)	4	FCVC, NCP, CH2O, FAF, TUE
Valores nulos	0	Dataset limpio — sin imputación requerida
Origen del dataset	UCI ML Repository	Palechor & de la Hoz Manotas, 2019
Países cubiertos	Colombia, Perú, México	77 % sintético, 23 % real
Precisión del modelo (test set)	95.5 %	RandomForestClassifier, n_estimators=100, random_state=42

Diccionario de columnas:

La siguiente tabla describe las 16 variables predictoras y la variable objetivo NObeyesdad. Los colores de tipo indican la naturaleza de cada variable: Numérico continuo, binario verde azulado, ordinal naranja y categórico nominal gris.

Tabla A.2. Diccionario de columnas: 17 variables del dataset

Variable	Nombre legible	Tipo	Valores posibles	Descripción
Gender	Género	Categórico	Male / Female	Sexo biológico del individuo
Age	Edad	Numérico	14 – 61 (años)	Edad del individuo en años
Height	Altura	Numérico	1.45 – 1.98 (m)	Altura en metros
Weight	Peso	Numérico	39 – 173 (kg)	Peso corporal en kilogramos
family_history_with_overweight	Historial familiar de sobrepeso	Binario	yes / no	Presencia de sobrepeso en familiares directos
FAVC	Consumo alimentos hipercalóricos	Binario	yes / no	Consumo frecuente de comida calórica
FCVC	Consumo de verduras	Ordinal	1 nunca / 2 A veces / 3 Siempre	Frecuencia de consumo de vegetales en las comidas
NCP	Comidas principales al día	Ordinal	1 / 2 / 3 / 4	Número de comidas principales diarias
CAEC	Consumo entre comidas	Categórico	no / Sometimes / Frequently / Always	Frecuencia de consumo de alimentos entre comidas
SMOKE	Fumador	Binario	yes / no	Si el individuo fuma activamente
CH2O	Consumo diario de agua	Ordinal	1 <1L / 2 1-2L / 3 >2L	Cantidad aproximada de agua consumida al día
SCC	Monitoreo de calorías	Binario	yes / no	Si el individuo monitorea sus calorías diarias
FAF	Frecuencia actividad física	Ordinal	0 Nada / 1 1-2d / 2 2-4d / 3 4-5d	Días por semana de actividad física moderada o intensa
TUE	Uso de dispositivos tecnológicos	Ordinal	0 0-2h / 1 3-5h / 2 >5h	Horas diarias frente a pantallas, sedentarismo digital
CALC	Consumo de alcohol	Categórico	no / Sometimes / Frequently / Always	Frecuencia de consumo de bebidas alcohólicas
MTRANS	Medio de transporte	Categórico	Automobile / Bike / Motorbike / Public_Transportation / Walking	Medio de transporte habitual
NObeyesdad	Nivel de obesidad (TARGET)	Categórico	7 clases (ver tabla B)	Variable objetivo: nivel de obesidad clasificado por el dataset

Ejemplo de Registros CVS:

A continuación, se muestran 5 filas del archivo obesity_data.csv para ilustrar el formato real del dataset. La columna NObeyesdad es la variable objetivo que predice el modelo. Los valores de FCVC, NCP, CH2O, FAF y TUE son enteros ordinales, el resto de las columnas categóricas aparecen en su forma original antes del preprocesamiento.

Tabla A.3. Ejemplo de 5 registros del archivo obesity_data.csv

Gen der	A g e	Hei ght	Wei ght	fam_ hist	FA VC	FC VC	N C P	CAEC	SM OK E	CH 20	S C C	F A F	T U E	CALC	MTRANS	NObesyda d
Fem ale	2 1	1.6 2	64. 0	yes	no	2	3	Some times	no	2	no	0	1	Some times	Public_Tran sportation	Normal_We ight
Mal e	2 2	1.8 0	89. 8	yes	yes	3	3	Some times	no	2	no	3	1	Some times	Automobile	Overweight _Level_II
Mal e	2 3	1.7 8	96. 0	yes	yes	3	3	Some times	no	3	no	3	0	Some times	Automobile	Obesity_Ty pe_I
Fem ale	2 4	1.7 1	75. 0	yes	yes	2	3	Some times	no	2	no	1	1	Some times	Public_Tran sportation	Overweight _Level_II
Mal e	3 6	1.7 2	119 .0	yes	yes	3	3	Some times	no	2	no	0	0	Some times	Automobile	Obesity_Ty pe_III

Pipeline de preprocesamiento

El siguiente pipeline describe cada transformación aplicada sobre el dataset, desde la carga del CSV hasta la inferencia en producción. Los pasos 1 a 6 ocurren durante el entrenamiento en la clase de model_service.py los pasos 7 a 8 ocurren en cada solicitud de predicción en producción ai_service.py.

1. Carga del dataset.

El proceso inició con la carga del archivo obesity_data.csv mediante pandas.read_csv(). El conjunto de datos contiene 2.111 filas y 17 columnas, y durante esta etapa no se identificaron valores nulos confirmados.

2. Codificación categórica.

Las variables de tipo categórico fueron transformadas con LabelEncoder de scikit-learn, aplicando un codificador independiente por cada columna. Esta codificación convirtió los valores textuales en representaciones numéricas aptas para el entrenamiento del modelo.

3. Serialización de encoders.

Una vez ajustados, los codificadores fueron almacenados en label_encoders.joblib mediante joblib.dump(). Este archivo permite que el entorno de producción reutilice exactamente los mismos mapeos aplicados durante el entrenamiento.

4. División train/test.

El conjunto de datos fue dividido con train_test_split(test_size=0.2), asignando aproximadamente el 80% de los registros al entrenamiento y el 20% restante a la prueba. Para asegurar reproducibilidad, se utilizó random_state=42.

5. Extracción de variables predictoras y objetivo.

La variable objetivo se definió a partir de NObesyedad, mientras que las 16 variables restantes fueron asignadas a X. La clase objetivo quedó codificada en siete categorías. No se aplicó escalado, debido a que Random Forest no requiere normalización de entrada.

6. Entrenamiento del modelo.

El clasificador fue entrenado mediante RandomForestClassifier(n_estimators=100), utilizando 100 árboles de decisión sobre X_train y y_train. El modelo alcanzó una precisión de 95.5% sobre el conjunto de prueba y fue guardado como obesity_rf_model.joblib.

7. Inferencia en producción.

Durante la inferencia, el perfil del usuario se convierte primero en un DataFrame y luego se transforman sus variables categóricas con los LabelEncoder persistidos. Después, los datos procesados se envían al modelo cargado con joblib.load(), y la predicción obtenida se decodifica mediante inverse_transform() para generar una salida legible, como

Overweight_Level_II.

8. Explicabilidad con SHAP.

Para la interpretación de resultados, se inicializa `shap.TreeExplainer(model)` al arrancar el servicio. En cada predicción se calculan los `shap_values` con el fin de identificar las tres características con mayor impacto positivo sobre la clase predicha, y esos factores se utilizan posteriormente como entrada para la generación del prompt destinado a Gemini.

Anexo B: Código relevante

El proyecto SRPHS está alojado en una organización GitHub centralizada que agrupa los repositorios de backend y frontend. A continuación, se presentan los enlaces de acceso a todos los recursos del sistema:

Tabla B.1. Repositorios y recursos del proyecto SRPHS

Recurso	Enlace
Organización GitHub	github.com/SRPHS-1
Repositorio Backend	github.com/SRPHS-1/SRPHS_BACKEND
Repositorio Frontend	github.com/SRPHS-1/SRPHS_FRONTEND
Aplicación Desplegada	srphs-frontend-...vercel.app
Documentación Swagger	srphs-backend.onrender.com/docs

Anexo C: Resultados completos de pruebas

Esta sección presenta los resultados detallados de los dos casos de prueba ejecutados sobre el prototipo SRPHS desplegado en producción. Se incluyen tablas comparativas de entradas, salidas y criterios de evaluación, así como una representación visual de la clasificación BMI de cada caso.

Tabla C.1. Variables de entrada por caso de prueba

Variable de entrada	Caso A — Exitoso	Caso B — Falla
Género	Female	Male
Edad	28 años	1 año
Altura	1.62 m	0.50 m ⚠
Peso	85 kg	200 kg ⚠
BMI calculado	32.4 kg/m ²	800 kg/m ² ⚠
Antecedentes sobrepeso	Sí	No
Comida hipercalórica	Sí	No
Consumo de vegetales	A veces	Siempre
Comidas principales	3	1
Snacks	Frecuentemente	No
Fumador	No	No
Agua diaria	1–2 L	>2 L
Monitoreo de calorías	No	Sí
Actividad física	Ninguna	4–5 días/semana
Uso de pantallas	5 h/día	0 h/día
Alcohol	A veces	No
Transporte	Automóvil	Caminando
Objetivo declarado	Perder peso	Ganar músculo

Comparación de salidas obtenidas

Tabla C.2. Comparación de salidas obtenidas por caso de prueba

Campo	Caso A: Salida obtenida	Caso B: Salida obtenida
Diagnóstico ML	Overweight_Level_II	Obesity_Type_I
BMI	32.4 kg/m ²	800 kg/m ² biológicamente imposible
Clasificación WHO	Obesidad	Obesidad sin advertencia
Rec. 1	Multiplica tus raciones de verduras (al menos mitad del plato)	Prioriza un plato inteligente: vegetales, proteína magra y carbohidratos complejos
Rec. 2	Rutina de 30 min de caminata enérgica la mayoría de los días	Bebe al menos 8 a 10 vasos de agua al día
Rec. 3	Comer con conciencia: porciones moderadas y comer despacio	Programa de fuerza: 3 a 4 sesiones de pesas por semana
Estado	EXITOSO	FALLA Sin validación fisiológica

El siguiente diagrama muestra la escala WHO de clasificación del BMI y ubica visualmente ambos casos de prueba en sus categorías correspondientes:

Tabla C.3. Análisis de fallas, causas y correcciones propuestas

Bajo peso < 18.5	Normal 18.5–24.9	Sobrepeso 25–29.9	Obesidad I 30–34.9	Obesidad II 35–39.9	Obesidad III ≥ 40
			▲ Caso A BMI: 32.4		▲ Caso B BMI: 800

Caso A (BMI 32.4): Clasificado correctamente como Obesidad I en rango 30 a 34.9. Las recomendaciones generadas son coherentes con esta clasificación y el objetivo de pérdida de peso declarado por el usuario.

Caso B (BMI 800): Técnicamente clasificado como Obesidad III por el modelo, pero sin ninguna validación de rango. El sistema generó recomendaciones para ganar músculo ignorando la inconsistencia extrema del perfil.

Referencias

Normas APA. (s. f.). *Referencias*. <https://normas-apa.org/referencias/>

Ministerio de Educación Nacional — SPADIES. (s. f.). *Estadísticas de deserción*.
<https://www.mineducacion.gov.co/sistemasinfo/spadies/secciones/Estadisticas-de-desercion/>

World Heart Federation. (s. f.). *Prevention of cardiovascular disease*. <https://world-heart-federation.org/what-we-do/prevention/>

World Health Organization. (2021). *Ambient (outdoor) air quality and health*. [https://www.who.int/news-room/fact-sheets/detail/ambient-\(outdoor\)-air-quality-and-health](https://www.who.int/news-room/fact-sheets/detail/ambient-(outdoor)-air-quality-and-health)

World Health Organization. (2022). *Cardiovascular diseases (CVDs)*. [https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-\(cvds\)](https://www.who.int/news-room/fact-sheets/detail/cardiovascular-diseases-(cvds))

World Health Organization. (2020). *Physical activity*. <https://www.who.int/news-room/fact-sheets/detail/physical-activity>

Organización Mundial de la Salud. (2023). *Noncommunicable diseases*. <https://www.who.int/news-room/fact-sheets/detail/noncommunicable-diseases>

Secretaría Distrital de Ambiente (Bogotá). (s. f.). *Calidad del aire*. <https://www.ambientebogota.gov.co/calidad-del-aire>

IDEAM (Instituto de Hidrología, Meteorología y Estudios Ambientales). (s. f.). *Calidad del aire — Información y monitoreo*.
<http://www.ideam.gov.co/web/atencion-y-participacion-ciudadana/calidad-del-aire>

Gil-Vera, J. A., & Quintero-López, C. (2021). *Predicción del rendimiento académico estudiantil con redes neuronales artificiales*. *Información Tecnológica*, 32(6), 221–232. <https://doi.org/10.4067/S0718-07642021000600221>
https://www.scielo.cl/scielo.php?script=sci_arttext&pid=SO718-07642021000600221&lng=en&nrm=iso&tlng=en

Banquez Maturana, A. G., Rodríguez Cerón, J. D., Benavides González, Á. M., & Felizzola Jimenez, H. A. (2025). *Desarrollo de un sistema inteligente para predecir la deserción universitaria en Colombia mediante técnicas de machine learning*. *Inge CuC*, 21(2).
<https://revistascientificas.cuc.edu.co/ingecuc/article/view/6752>

Dominguez-Miranda, A., & Rodriguez-Aguilar, J. (2024). *Análisis co-word sobre la aplicación de modelos de machine learning en prevención y promoción de la salud* [Art. en *Iberoamerican Journal of Science Measurement and Communication*, 4(1)].
<https://ijsmc.pro-metrics.org/index.php/i/article/view/85>

Calderón Blas, J. A., Cerdán, M. A., Sánchez García, Á. J., & Domínguez Isidro, S. (2023). *Inteligencia artificial en sistemas de recomendación médica: una revisión de la literatura*. *ReCIBE*.
<https://recibe.cucei.udg.mx/index.php/ReCIBE/article/view/311>

Sarmiento Sánchez, C. A. (2024). *[Modelos LSTM para predicción de contaminantes en Bogotá]*. *Ingenio Tecnológico*, 6, e051.
<https://ingenio.frlp.utn.edu.ar/index.php/ingenio/article/view/108>

Naranjo Rojas, R., & Vega Linares, L. (2024). *Implementación de un modelo de machine learning para el análisis de la calidad del aire en Puente Aranda* [Tesis de pregrado, Universidad Cooperativa de Colombia]. Repositorio UCC.
<https://hdl.handle.net/20.500.12494/58137>

Departamento Administrativo Nacional de Estadística (DANE). (2025). *Boletín — Estadísticas vitales: Defunciones 2024 (preliminar)*. <https://www.dane.gov.co/files/operaciones/EEVV/2024/19-dic-2024/bol-EEVV-Defunciones-2024pr.pdf>

National Institute for Health and Care Excellence. (2014). *Obesity: Identification, assessment and management (CG189)*.
<https://www.nice.org.uk/guidance/cg189>

Palechor, F.M., & de la Hoz Manotas, A. (2019). *Dataset for estimation of obesity levels based on eating habits and physical condition in individuals from Colombia, Peru and Mexico*. *Data in Brief*, 25, 104344.
<https://doi.org/10.1016/j.dib.2019.104344>

Pedregosa, F, Varoquaux, G., Gramfort, A., Michel, V, Thirion, B., Grisel, O, ... & Duchesnay, É. (2011). *Scikit-learn: Machine learning in Python*. *Journal of Machine Learning Research*, 12, 2825–2830. <http://jmlr.org/papers/v12/pedregosa11a.html>

Herlocker, J. L., Konstan, J. A., Terveen, L. G., & Riedl, J. (2004). *Evaluating collaborative filtering recommender systems*. *ACM Transactions on Information Systems*, 22(1), 5–53. <https://doi.org/10.1145/963770.963772>

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
<https://www.stat.berkeley.edu/~breiman/randomforest2001.pdf>

Koren, Y., Bell, R., & Volinsky, C. (2009). Matrix factorization techniques for recommender systems. *Computer*, 42(8), 30–37.
<https://doi.org/10.1109/MC.2009.263>

Hug, N. (2020). Surprise: A Python library for recommender systems. *Journal of Open Source Software*, 5(52), 2174.
<https://doi.org/10.21105/joss.02174> (Documentación: <https://surprise.readthedocs.io/>)

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30. <https://arxiv.org/abs/1705.07874>

Adomavicius, G., & Tuzhilin, A. (2005). Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engineering*, 17(6), 734–749.
<https://doi.org/10.1109/TKDE.2005.99>

FastAPI. (s. f.). *FastAPI: High performance web framework*. <https://fastapi.tiangolo.com/>

React. (s. f.). *React documentation*. <https://react.dev/>

Vite. (s. f.). *Next generation frontend tooling*. <https://vite.dev/>